Adaptive Sketching for Tensor Network Contraction

Kaiyu Shen

Abstract

本文研究一类张量网络收缩问题：目标不是计算单个标量结果，而是生成完整的输出张量。在误差评估、可视化与跨系统接口等场景中，下游真正需要的是完整的稠密输出。此时，问题的关键不在于改变输出形式，而在于如何在保持完整输出要求不变的前提下，降低生成该输出所需的内部收缩代价。为此，本文提出 AS-TNC 方法：先对输出索引空间做分块，再在交互图上构造划分树，并沿树递归维护分隔状态；方法始终保持输出边界显式存在，只对内部接口做自适应低秩近似，并在内部合并处通过基于算子访问的隐式草图合并避免显式形成膨胀接口。

实验围绕多种经典张量网络展开，主要关注三个问题：AS-TNC 是否能够形成可用的精度–时间折中，收益是否确实来自收缩阶段，以及近似强度能否稳定控制误差。结果表明，在代表性实验中，AS-TNC 将相对误差控制在 4.81×10^{-3} 以内，并相对直接 TNC 获得 $13.98\times$ 到 $84.05\times$ 的加速；相比之下，固定小秩基线虽然更快，但相对误差达到 0.65–0.98。进一步分析表明，端到端加速几乎完全来自收缩阶段；机制分析则说明，隐式草图合并是主要效率来源，输出分块同样带来实质帮助。近似强度扫描实验进一步表明，近似强度可以有效控制误差与时间之间的权衡。

1 引言

张量网络为高维数组的表示与计算提供了紧凑而有结构的形式，已广泛应用于量子多体计算、统计物理、图模型推断以及张量算法等方向 [19]。围绕张量网络收缩（TNC），已有研究主要关注三类问题：如何设计更优的收缩顺序，如何控制中间状态规模，以及如何通过中间状态压缩降低近似收缩的代价 [18, 7, 15, 11, 14, 20, 10, 17]。这些工作大多面向标量结果计算、局部可观测量计算或概率推断中的局部查询，而不是在保留开放腿的情况下显式生成完整输出张量 [19, 4, 20, 13]。相比之下，一旦任务目标变为完整输出计算，计算与存储开销都会显著膨胀 [15]。本文关注的正是这一类带开放腿张量网络的完整输出计算问题。

这一问题与通常的近似收缩存在根本区别：当完整输出本身就是任务目标时，算法不能将其替换为压缩表示，也不能只返回少量局部结果。因此，本文关注的不是改变输出形式，而是在保持完整输出要求不变的前提下，降低生成该输出所需的计算开销。若将端到端时间写为

$$T_{\text{total}} = T_{\text{contract}} + T_{\text{emit}},$$

其中，T_{contract} 表示生成目标输出之前的内部计算开销，包括网络内部的收缩、合并以及相关中间状态处理；T_{emit} 表示将这些结果显式写入完整输出张量的开销。由于完整输出本身必须被生成，T_{emit} 往往不可避免，因此方法设计的主要优化对象通常是 T_{contract}。

基于这一观察，本文研究一种面向完整输出计算的近似收缩框架。其基本思路是：先对输出索引空间进行分块，再在网络交互图上构造划分树，并沿树递归维护各个子网络的分隔状态；在整个过程中，输出边界始终保持显式，只对内部传播的分隔状态进行近似。因此，本文近似的不是最终输出对象，而是“为了得到该输出而必须经过的内部中间状态”。这也是本文与直接压缩输出端的方法，以及以标量收缩为目标的方法之间最本质的区别。

从表示上看，每个子树状态都可以理解为一个从输出侧到边界侧的接口矩阵。本文在划分树上递归传播这一状态，并通过低秩因子化与合并后再压缩来抑制中间维度增长。进一步地，针对内部节点合并时容易出现的接口膨胀，本文引入基于算子访问的隐式草图合并，不显式形成完整的合并接口，而是直接恢复其主导子空间。因此，本文的核心并不是某一个孤立的局部技巧，而是将输出分块、划分树递归、分隔状态近似与草图驱动的合并压缩组织成一条统一的收缩流程。在这条流程中，输出语义保持不变，近似只服务于降低内部收缩成本。

实验部分围绕三个问题展开：第一，AS-TNC 在带开放腿张量网络收缩任务中能否形成清楚而可用的精度–时间折中；第二，这些收益是否确实来自收缩阶段，以及哪些机制在较难网络上最关键；第三，近似强度是否能够稳定控制误差。结果表明，在代表性经典网络上，AS-TNC 将相对误差控制在 4.81×10^{-3} 以内，同时相对直接 TNC 获得 $13.98\times$ 到 $84.05\times$ 的加速；而固定秩基线虽然更快，却带来 0.65 到 0.98 的大误差。进一步分析表明，端到端收益几乎完全来自收缩阶段；隐式草图合并是更稳定也更核心的效率来源，输出分块同样具有实质作用。近似强度扫描实验则显示，近似强度可以作为控制误差的有效调节旋钮。

本文的贡献可以概括为三点：

- 针对带开放腿张量网络的完整输出计算任务，本文将近似的位置从输出端移到内部收缩过程，关注在保持完整输出要求不变的前提下降低内部计算代价。
- 本文提出 AS-TNC 框架：通过输出分块与划分树递归维护分隔状态，利用自适应低秩压缩控制状态规模，并在内部合并处引入隐式草图合并，以避免显式形成膨胀接口。
- 本文在 Ring-8、Tree-8、Grid 3×3 与 Random-8 上系统验证了该方法，结果表明 AS-TNC 能够形成清楚的精度–时间折中，并揭示了其主要收益来源与关键机制。

2 相关工作

精确张量网络收缩。 精确张量网络收缩的经典研究主要围绕收缩顺序、收缩树、树宽以及切片策略展开。这一路线的核心结论很明确：真正决定复杂度的往往不是单个张量本身，而是中间状态的规模，以及由此诱导出的时间与空间开销 [18, 7, 15, 11]。在此基础上，index slicing 又进一步说明，当一次计算难以承受时，可以把部分自由度切出来，转化为许多更小的子任务来并行执行或分批完成 [14]。这些工作为本文提供了两个直接启发：一是困难首先来自中间分隔结构的膨胀；二是按块组织计算可以成为完整输出计算中的重要系统手段。不过，这一方向的主要目标仍然是精确收缩，而不是在完整输出仍需显式生成的前提下，对内部收缩过程进行近似优化。

近似收缩与中间状态压缩。 当精确收缩代价过高时，近似张量网络方法通常通过压缩中间对象来控制复杂度。在规则拓扑上，TRG 等工作已经表明：面对不可承受的中间状态，能否做出有效截断，是近似收缩能否成立的关键 [16]。近年来，这一思路逐渐从规则晶格走向一般图结构。Pan 等人提出了适用于任意连通结构的一般性近似收缩算法 [20]；Gray 和 Chan 将近似直接纳入收缩规划过程，使压缩与收缩顺序能够联合优化 [10]；Ma 等人则发展了面向一般图的 density-matrix 风格近似框架 [17]。这些工作说明，一般图上的近似收缩已经可以系统地开展。不过，相比已有面向一般图的近似收缩方法，本文关注的是带开放腿张量网络的完整输出计算任务。在这一任务中，输出张量需要被完整生成，算法不能通过改变输出形式来规避计算代价。因此，本文更强调在保持输出边界显式存在的前提下，对内部传播的分隔状态进行近似，并将这种近似组织到完整的收缩流程之中。

随机化低秩近似与草图。 本文的方法也借鉴了随机化数值线性代数与草图的思想。随机化低秩近似表明，在许多大规模问题中，可以先用随机投影快速捕捉主导子空间，再在较小的子空间内做稳定分解，而不必一开始就构造昂贵的精确分解 [12]。更一般地，Count Sketch 与 Tensor Sketch 等方法展示了随机线性映射在高维对象压缩中的作用 [2, 21]。非常近期的工作也开始直接讨论张量网络收缩中的草图近似 [13]。在本文中，随机化压缩是分隔状态框架中的实现工具之一，其作用是降低内部状态压缩的代价，而不是改变本文的问题设定。

与图模型消去方法的关系。 从算法结构上看，本文也与图模型中的 bucket elimination 和 mini-bucket 有相通之处 [3, 5]。这些方法同样强调：真正向上层传播的不是局部对象的全部细节，而是与外部仍然相关的接口信息；当接口过大时，就需要在中间层面做受控近似。本文将这一思想放在带开放腿张量网络的完整输出计算任务下重新组织，并把输出边界保持视为方法定义的一部分。

综上，已有工作已经分别从精确收缩、一般图近似收缩、随机化低秩近似以及图模型消去等角度，为控制张量网络中的中间状态提供了丰富工具。本文与这些工作的区别不在于重新发明某一种局部压缩手段，而在于将这些思想重新组织到带开放腿张量网络的完整输出计算任务中：输出张量仍需被完整生成，近似不发生在输出端，而发生在内部收缩过程中传播的分隔状态上。本文的方法正是在这一问题设定下，对划分树递归、分隔状态表示、自适应压缩与草图合并进行统一组织的结果。

3 方法

3.1 整体思路

设 $\mathcal{N}$ 为一个带开放腿的张量网络，其开放标签集合记为 $\mathcal{O}$，内部收缩标签集合记为 $\mathcal{I}$。将所有内部标签收缩后，可得到完整输出张量 $X \in \mathbb{R}^{d_1 \times \cdots \times d_{|\mathcal{O}|}}$. 相应地，端到端时间可写为

$$T_{\text{total}} = T_{\text{contract}} + T_{\text{emit}},$$

其中 T_{contract} 表示生成输出之前的内部收缩、状态合并与近似压缩代价，T_{emit} 表示将结果写回完整输出张量的代价。由于完整输出本身必须被生成，T_{emit} 往往难以避免，因此真正值得优化的主要是 T_{contract}。基于这一判断，本文把近似严格限制在内部传播的分隔状态上，而不直接压缩输出边界。

整条方法主线可以概括为四步：

1. 将完整输出张量按若干开放输出轴划分为多个输出块，并按块执行收缩与写回；
2. 在网络交互图上构造一棵划分树，把一般图上的收缩过程写成一系列合并；
3. 对每个子树，用分隔状态来概括它对外仍然可见的信息；
4. 沿树递归合并这些分隔状态，并在每次合并后重新压缩，以控制中间状态规模。

3.2 划分树与分隔状态

为了统一组织一般图上的递归收缩，我们在张量网络的交互图上构造一棵划分树。树上的每个节点 v 对应一个子网络 $\mathcal{N}_v$；叶节点对应单个原始张量，内部节点对应两个子网络的合并，根节点对应整个网络。

对任意节点 v，我们关心三类标签：

- 输出标签 $\mathcal{O}_v$：该子树最终仍通向输出侧的标签；
- 边界标签 $\mathcal{B}_v$：该子树与外部其余网络连接所需保留的标签；
- 切割标签 $\mathcal{C}_v$：当 v 由两个孩子合并而成时，连接左右孩子并在本层被消去的标签。

根节点不再与外部网络相连，因此其边界标签为空；叶节点不再继续拆分，因此没有切割标签。

给定输出块 Ω_b 后，我们将节点 v 的分隔状态定义为

$$M_v \in \mathbb{R}^{d_{\text{open}}(v) \times d_{\text{bnd}}(v)},$$

其中

$$d_{\text{open}}(v) = \prod_{\ell \in \mathcal{O}_v} d_\ell, \qquad d_{\text{bnd}}(v) = \prod_{\ell \in \mathcal{B}_v} d_\ell.$$

这里 d_ℓ 表示标签 ℓ 的维度，矩阵 M_v 的行对应输出侧配置，列对应边界侧配置，因此它刻画了当前子树在输出块 Ω_b 下对父节点可见的局部行为。

直接显式存储 M_v 往往代价过高，因此我们采用低秩因子形式

$$M_v \approx A_v (B_v)^\top,$$

其中

$$A_v \in \mathbb{R}^{d_{\text{open}}(v)\times r_v}, \qquad B_v \in \mathbb{R}^{d_{\text{bnd}}(v)\times r_v},$$

r_v 是节点 v 的接口秩。这种写法把输出侧与边界侧显式分开，也清楚地说明了本文的近似位置：输出边界保持不变，近似只发生在分隔状态上。

3.3 树的递归合并

在定义了分隔状态之后，整棵划分树上的计算就可以写成统一的递归。

叶节点。 对叶节点 v，其子网络只包含一个原始张量，把张量重排成

$$T_v \in \mathbb{R}^{d_{\text{open}}(v)\times d_{\text{bnd}}(v)}.$$

若不做近似，则 T_v 就是该叶节点的精确分隔状态；若做近似，则对 T_v 做低秩压缩，得到

$$M_v \approx A_v (B_v)^\top.$$

内部节点。 设内部节点 v 的两个孩子为 v_L 和 v_R，其分隔状态分别为

$$M_{v_L} \approx A_{v_L} (B_{v_L})^\top, \qquad M_{v_R} \approx A_{v_R} (B_{v_R})^\top.$$

父节点的构造可分为三步。

(i) 合并输出侧。 父节点的输出标签满足

$$\mathcal{O}_v = \mathcal{O}_{v_L} \cup \mathcal{O}_{v_R}, \qquad \mathcal{O}_{v_L} \cap \mathcal{O}_{v_R} = \varnothing.$$

因此，父节点的输出侧配置空间是左右孩子输出侧配置空间的笛卡尔积。在因子层面，这一步对应于将两个孩子的输出侧因子做 Kronecker 积

$$A_{\text{mat}} = A_{v_L} \otimes A_{v_R},$$

其列数为 $r_{v_L} r_{v_R}$。

(ii) 收缩切割标签，保留边界标签。 设父节点保留的边界标签集合为 $\mathcal{B}_v$，本层被消去的切割标签集合为 $\mathcal{C}_v$。则父节点未压缩的边界侧因子可以看成对两个孩子的边界侧因子沿 $\mathcal{C}_v$ 做收缩：

$$B_{\text{mat}} = B_{v_L} \times_{\mathcal{C}_v} B_{v_R}.$$

(iii) 重新压缩。 经过前两步后，父节点得到未压缩表示

$$\widetilde{M}_v = A_{\text{mat}} B_{\text{mat}}^\top.$$

由于其中的中间列数已经膨胀到 $r_{v_L} r_{v_R}$，若不立即重压缩，秩会在树上迅速增长。因此，我们对 $\widetilde{M}_v$ 再做一次低秩压缩，写回统一的分隔状态形式

$$M_v \approx A_v (B_v)^\top.$$

3.4 自适应秩选择

在分隔状态递归中，每次叶节点构造和内部节点合并之后，都要对当前分隔状态重新压缩，以防止秩在树上不断膨胀。最直接的做法是为所有节点统一指定一个固定秩 r。这种方案实现简单，但它默认划分树上不同节点的分隔状态难度大致相同；这一假设在实际中通常并不成立。不同节点对应的子树规模以及谱衰减特性都可能差别很大。有些节点本身较简单，较低秩已经足够；另一些节点则包含更复杂的内部耦合，若仍采用统一秩预算，就会过早丢失关键信息。因此，固定秩往往会同时带来两类问题：在简单节点上保留了多余通道，在困难节点上又压得不够。

基于这一观察，本文在每个待压缩节点上按局部误差容忍度自适应选择秩，而不是预先指定统一目标秩。设某个待压缩接口矩阵为

$$M \in \mathbb{R}^{m\times n},$$

其奇异值分解为

$$M = U\Sigma V^\top, \qquad \Sigma = \mathrm{diag}(\sigma_1, \sigma_2, \ldots).$$

若取其秩-r 截断近似

$$M_r = U_r \Sigma_r V_r^\top,$$

则 Frobenius 范数下的相对误差为

$$\frac{\|M - M_r\|_F}{\|M\|_F} = \left(\frac{\sum_{i>r}\sigma_i^2}{\sum_i \sigma_i^2}\right)^{1/2}.$$

因此，给定容忍度 τ，我们选择满足

$$\left(\frac{\sum_{i>r}\sigma_i^2}{\sum_i \sigma_i^2}\right)^{1/2} \le \tau$$

的最小秩 r。在实现中，叶节点与内部合并节点可分别使用不同的容忍度，记为 τ_{leaf} 与 τ_{merge}。

这种做法把“每个节点保留多少通道”转化成“每个节点允许损失多少相对能量”。谱衰减快的简单节点会自动停在较低秩，而谱衰减慢的困难节点会自动保留更多通道。因此，自适应秩选择的关键在于按局部难度重新分配秩预算。

3.5 隐式草图合并

仅靠自适应秩选择还不够。在内部节点处，若左右孩子的秩分别为 r_L 和 r_R，则父节点在重压缩之前自然会出现

一个秩乘积 $r_L r_R$。如果先显式构造合并后的大接口矩阵，再对它做普通低秩分解，就会遇到中间瓶颈。为此，本文引入隐式草图合并：不显式形成完整的合并接口，而是通过算子访问直接恢复其主导子空间 [12, 13]。

设合并后待压缩的父节点接口为

$$\widetilde{M} \in \mathbb{R}^{m\times n}.$$

在显式路径中，它可以写成

$$\widetilde{M} = A_{\text{mat}} B_{\text{mat}}^{\top},$$

其中 A_{mat} 来自输出侧因子的组合，B_{mat} 来自边界侧因子沿切割标签的收缩。隐式草图合并真正需要的不是 $\widetilde{M}$ 的全部条目，而是对线性算子 $\widetilde{M}x$ 和 $\widetilde{M}^{\top}y$ 的访问。在本文的合并结构下，这两个乘法可写为

$$\widetilde{M}x = A_{\text{mat}}\big(B_{\text{mat}}^{\top}x\big), \qquad \widetilde{M}^{\top}y = B_{\text{mat}}\big(A_{\text{mat}}^{\top}y\big).$$

因此，整个压缩过程都可以建立在算子之上，而不必先显式形成完整的 $\widetilde{M}$。

在此基础上，我们借鉴 randomized SVD 的思想 [12]。首先生成高斯随机测试矩阵

$$\Omega \in \mathbb{R}^{n\times \ell}, \qquad \Omega_{ij} \sim \mathcal{N}(0,1),$$

其中 $\ell = k+p$，k 是目标秩的估计规模，p 是过采样参数。然后构造样本矩阵

$$Y_0 = \widetilde{M}\Omega.$$

这里的 Y_0 并不是通过显式矩阵乘法得到，而是通过对 Ω 逐列或成块应用算子 $\widetilde{M}$ 得到。当谱衰减较慢时，为了更稳定地提取主导子空间，还可以做 q 次幂迭代：

$$Y_{t+1} = \widetilde{M}\big(\widetilde{M}^{\top}Y_t\big), \qquad t = 0,1,\ldots,q-1.$$

随后对最终样本矩阵做正交化，得到

$$Q = \text{orth}(Y_q) \in \mathbb{R}^{m\times \ell},$$

其中 Q 近似张成了 $\widetilde{M}$ 的主导列空间。再将原问题压缩到小矩阵

$$M_{\text{proj}} = Q^{\top}\widetilde{M} \in \mathbb{R}^{\ell\times n}$$

上，并对其做精确 SVD：

$$M_{\text{proj}} = \widetilde{U}\Sigma V^{\top}.$$

到这一步为止，原来的大接口已经被转化成一个小矩阵上的谱截断问题。直接采用固定秩可以直接保留前 r 个奇异方向；而本文主线采用基于尾能量的自适应截断：给定合并容忍度 τ，选择满足

$$\left(\frac{\sum_{i>r}\sigma_i^2}{\sum_i \sigma_i^2}\right)^{1/2} \le \tau$$

的最小秩 r。设据此得到的截断结果为

$$\widetilde{M} \approx Q\widetilde{U}_r \Sigma_r V_r^{\top},$$

为了与全文统一的分隔状态表示保持一致，我们将其写回为因子形式

$$A = (Q\widetilde{U}_r)\Sigma_r^{1/2}, \qquad B = V_r\Sigma_r^{1/2},$$

从而得到

$$\widetilde{M} \approx AB^{\top}.$$

如果说自适应秩选择决定“最终保留多少通道”，那么隐式草图合并决定“如何在不显式形成膨胀接口的情况下找到这些通道”。

3.6 输出分块与块级状态复用

完整输出张量通常不会一次性生成，而是沿若干开放输出轴划分为多个小块，按块逐步收缩并写回。设全局开放标签顺序为

$$\mathcal{O} = (\ell_1, \ell_2, \ldots, \ell_m).$$

为了简单起见，本文选取其中前 q 个开放标签作为分块轴，并将每个分块轴上的索引集合划分为若干局部片段。一个输出块 Ω_b 即由这些局部片段的笛卡尔积给出。

这里的输出分块不只是写回时的调度单位。更重要的是，在固定某个输出块后，部分开放标签在当前块中只剩下较小的局部自由度，因此各个子树所见到的输出侧规模也会随之改变。这会直接影响分隔状态的行维大小，从而改变整个递归收缩过程中的中间状态规模。

进一步地，不同全局输出块在某些子树上往往诱导出相同的局部限制条件。如果一个子树在两个不同输出块下看到的是同一组局部输出切片，那么该子树状态就可以跨块复用，而不必重复构造。因此，本文在块级收缩过程中缓存已经构造过的分隔状态，并在后续输出块中按局部条件进行复用。从系统角度看，输出分块与块间状态复用共同决定了完整输出计算的组织方式。

需要强调的是，为了保证比较公平，本文的精确基线与近似方法使用同一组输出块，并采用相同的块级写回接口；它们的差别只在于内部收缩如何组织：精确基线对每个输出块直接执行精确全网络收缩，而本文方法则通过划分树上的分隔状态递归完成近似收缩。

3.7 算法总览

为了便于整体把握，Algorithm 1 给出本文方法的主流程。它把前文的几个核心部件统一起来：输出分块负责组织完整输出计算过程，划分树负责把一般图上的收缩写成递归合并，分隔状态负责在树上向上传播局部信息，而重压缩则用于控制中间状态规模。划分树构造、局部块键缓存、精确收缩基线的实现接口以及随机化压缩的可重复性设置见附录 Section A.1。

4 实验

本节围绕三个问题组织实验：第一，AS-TNC 在带开放腿张量网络的完整输出计算任务中，是否形成了清楚而可用的精度–时间折中；第二，这些收益是否确实来自内部收缩，以及隐式草图合并、缓存复用与输出分块分别起什么作用；第三，近似强度是否能够作为稳定的误差调控旋钮。

算法 1 AS-TNC 的完整输出计算主流程

输入： 张量网络 $\mathcal{N}$，输出块集合 $\{\Omega_b\}_{b=1}^{B}$，压缩配置 θ
输出： 完整输出张量 X

```
在 N 的交互图上构造划分树 T
初始化输出缓冲区 X
初始化状态缓存 C
for 每个输出块 Ω_b do
    S_root ← 构造状态(root(T), Ω_b, θ, C)
    X[Ω_b] ← 根节点读出(S_root)
end for
return X
function 构造状态 (v, Ω_b, θ, C)
    if (v, Ω_b, θ) 对应状态已在缓存中可复用 then
        return 缓存状态
    end if
    if v 是叶节点 then
        在输出块 Ω_b 的限制下形成局部张量 T_v
        在 (O_v, B_v) 上构造分隔状态 M_v
        视需要对 M_v 做压缩
        将状态存入缓存并返回
    else
        S_L ← 构造状态(v_L, Ω_b, θ, C)
        S_R ← 构造状态(v_R, Ω_b, θ, C)
        合并 S_L 与 S_R 的输出侧因子
        沿切割标签 C_v 收缩边界侧因子
        对合并后的分隔状态重新压缩
        将状态存入缓存并返回
    end if
end function
function 根节点读出 (S_root)
    收回根状态的最后一条秩维
    return 与 Ω_b 对应的稠密输出块
end function
```

4.1 实验设置

我们主要报告四类有代表性的网络：Ring-8 [1]、Tree-8 [6]、Grid 3×3 [16, 19] 与 Random-8 [8, 9]；其中，8 表示节点数，3×3 表示二维网格规模。每个节点都带 1 条开放腿，物理维统一取 3，键维统一取 4。

AS-TNC 采用三档近似强度预设，分别记为 L1、L2 与 L3，对应由弱到强的近似。如无明确说明，默认为中等强度预设 L2。

除特别说明外，主实验均按分块策略进行，取前两个开放标签为分块轴，且各轴上的局部片段长度均为 1. 对比方法包括精确收缩基线 exact-TNC 和固定秩基线 FR-TNC。为了保证比较公平，都使用同一张量网络实例、同一开放标签顺序以及同一组输出块，并采用相同的块级写回接口；差别只在内部收缩组织方式：exact-TNC 对每个输出块直接执行一次精确全网络收缩，而 FR-TNC 和 AS-TNC 则通过划分树上的分隔状态递归完成收缩。

网络构造、容忍度预设、精确后端、计时口径以及实现参数与论文表述的对应关系见附录 Section A.2。

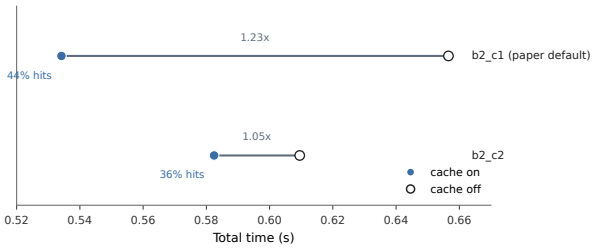

Figure 1: Grid 3×3 上 cache reuse 的成对对照。对齐设置下，开启 cache 在两组相邻分块设置上都带来稳定降时，正文默认设置上的提升最明显。

4.2 主结果

Table 1 给出了四个典型网络上的主结果。可以看到，固定秩基线虽然很快，但在四个网络上都产生了明显失真：其相对误差介于 0.65 到 0.98 之间。相比之下，默认 AS-TNC 配置在四个网络上都将相对误差控制在 4.81×10^{-3} 以内，同时相对 exact-TNC 仍获得了 $8.97\times$ 到 $88.45\times$ 的加速。最具区分度的结果来自 Grid 3×3：exact-TNC 需要 47.25 秒，而 AS-TNC 将总时间降到 0.5342 秒，相对误差仅为 4.08×10^{-3}。在四个主结果网络上，AS-TNC 的几何平均加速达到 $35.08\times$，平均相对误差为 2.68×10^{-3}。这表明 AS-TNC 在保持较高精度的同时，能够显著降低完整输出计算所需总时间。

4.3 收缩主导与机制作用

首先，我们考察端到端收益究竟来自哪里。由 Table 2 可见，在四个主结果网络上，默认 AS-TNC 配置的平均 $t_{\text{contract}}/t_{\text{total}}$ 达到 0.9993；其平均收缩加速比与总加速比分别为 $46.25\times$ 与 $46.23\times$，几乎完全一致。这说明 AS-TNC 的主要收益确实来自内部收缩阶段，而不是输出写回。以 Grid 3×3 为例，收缩加速为 $88.48\times$，总加速为 $88.45\times$，二者在数值上几乎重合。

接着，我们在 Grid 3×3 这一最具区分度的网络上隔离关键机制。结果如 Table 3 所示。去掉隐式草图合并后，误差几乎不变，但总时间恶化到默认设置的 $2.21\times$；这说明隐式草图合并是稳定且核心的效率来源。去掉缓存复用后，误差同样几乎不变，但总时间上升为默认设置的 $1.23\times$，表明块间状态复用能够带来额外但稳定的系统收益。相比之下，去掉输出分块后，总时间并未显著变差，但误差从 4.08×10^{-3} 上升到 1.06×10^{-2}，同时内部峰值秩由 64 上升到 222。这说明输出分块在当前小规模设置下更像是在塑造一个更优的精度–效率工作点，而不是一个单调的纯加速开关。

为了把缓存复用的收益更直观地呈现出来，我们进一步给出一张成对对照图。由 Figure 1 可见，在对齐设置下，cache 在两组相邻分块设置上都带来稳定的降时效果；其中正文默认设置上的提升最明显。更完整的 blockwise 设计空间与机制指纹可视化见附录 Figures 2 and 3。

4.4 近似强度与连续前沿

我们接着考察近似强度是否能够作为稳定的误差调控旋钮。Table 4 给出了离散的三档强度扫描结果。可以看到，从 L1 到 L2 再到 L3，误差整体上呈现清楚的上升

Table 1: 四个典型网络上的主结果：exact-TNC、固定秩基线与 AS-TNC 的精度–时间折中对比。

Case	exact-TNC time (s)	fixed-rank rel. error	fixed-rank speedup	AS-TNC rel. error	AS-TNC speedup
Ring-8	3.3502	0.8058	112.70×	1.83×10^{-3}	41.61×
Tree-8	1.0964	0.6524	59.53×	4.81×10^{-3}	45.88×
Grid 3×3	47.2469	0.9789	444.01×	4.08×10^{-3}	88.45×
Random-8	0.7339	0.9283	31.53×	$< 10^{-12}$	8.97×
Summary	—	—	—	avg. $= 2.68\times10^{-3}$	gmean $= 35.08\times$

Table 2: 时间阶段分解证据：AS-TNC 的端到端收益几乎全部来自收缩阶段，而非输出写回。

Case	$t_{\text{contract}}/t_{\text{total}}$	$t_{\text{emit}}/t_{\text{total}}$	contraction speedup	total speedup
Ring-8	0.9995	0.000470	41.63×	41.61×
Tree-8	0.9986	0.001342	45.94×	45.88×
Grid 3×3	0.9997	0.000303	88.48×	88.45×
Random-8	0.9994	0.000480	8.97×	8.97×
Average	0.9993	0.000649	46.25×	46.23×

Table 3: Grid 3×3 上的核心机制证据。默认配置指中等强度 AS-TNC，沿前两个输出轴按单索引块逐块生成完整输出，并同时启用缓存复用与隐式草图合并。

Setting	rel. error	total time (s)	time ratio vs. default	cache hit rate
AS-TNC (default)	4.08×10^{-3}	0.5342	1.00	0.440
no-blockwise	1.06×10^{-2}	0.5265	0.986	0
no-implicit	4.08×10^{-3}	1.1792	2.21	0.440
no-cache	4.08×10^{-3}	0.6566	1.23	0

趋势。以 Grid 3×3 为例，相对误差从近乎机器精度上升到 4.08×10^{-3}，再增至 1.81×10^{-2}；Tree-8 上则从近乎零误差上升到 4.81×10^{-3}，再达到 4.86×10^{-2}。四个网络上的平均相对误差分别为近乎零、3.59×10^{-3} 与 2.37×10^{-2}。这说明近似强度首先是一个有效的误差调控旋钮：更弱的近似更接近精确结果，而更强的近似则带来更大的误差。

5 结论

本文研究了带开放腿张量网络的完整输出计算问题。与传统近似收缩主要面向标量结果或局部查询不同，本文关注的是这样一类任务：最终结果必须以完整张量的形式被显式生成，因此方法设计不能通过改变输出形式来规避计算代价。基于这一设定，本文将优化重点放在内部收缩过程，并提出了 AS-TNC 框架。

围绕这一目标，本文将完整输出的生成过程组织为一条统一流程：先对输出索引空间进行分块，再在网络交互图上构造划分树，并沿树递归维护保持输出边界显式存在的分隔状态；在状态传播过程中，通过自适应低秩压缩和隐式草图合并抑制内部接口在合并阶段的维度膨胀。因此，AS-TNC 近似的不是最终输出对象，而是生成该输出过程中必须经过的内部分隔状态。

实验结果表明，AS-TNC 在 Ring-8、Tree-8、Grid 3×3 与 Random-8 上能够形成清楚且可用的精度–时间折中：在保持较小相对误差的同时，相对直接 TNC 获得显著加速。进一步的阶段拆解与机制分析说明，端到端收益几乎完全来自收缩阶段；其中，隐式草图合并是更核心也更稳定的效率来源，输出分块同样具有实质作用。强度扫描实验则进一步表明，近似强度可以作为控制误差与时间权衡的有效调节旋钮。

总体而言，本文说明了：当完整输出是不可改变的任务要求时，近似收缩的合理位置并不在输出端，而在内部收缩过程中传播的分隔状态。沿着这一思路，划分树递归、分隔状态表示与草图驱动压缩可以被组织成一个统一且有效的收缩框架。未来工作可进一步面向更大规模和更复杂的任务，继续完善选择性近似、缓存复用和更丰富的草图策略，使这种面向完整输出计算的近似收缩方法在更广泛场景下发挥作用。

Table 4: 近似强度调控证据：从 L1 到 L2 再到 L3，误差整体上升。

Case	L1 rel. error	L2 rel. error	L3 rel. error
Ring-8	$< 10^{-12}$	1.83×10^{-3}	1.55×10^{-2}
Tree-8	$< 10^{-12}$	4.81×10^{-3}	4.86×10^{-2}
Grid 3×3	$< 10^{-12}$	4.08×10^{-3}	1.81×10^{-2}
Random-8	$< 10^{-12}$	$< 10^{-12}$	1.26×10^{-2}
Average rel. error	$< 10^{-12}$	3.59×10^{-3}	2.37×10^{-2}

References

[1] J. A. Bondy and U. S. R. Murty. *Graph Theory*. Springer, 2008.

[2] Moses Charikar, Kevin Chen, and Martin Farach-Colton. “Finding Frequent Items in Data Streams”. In: *Theoretical Computer Science* 312.1 (2004), pp. 3–15. doi: 10.1016/S0304-3975(03)00400-6.

[3] Rina Dechter. “Bucket Elimination: A Unifying Framework for Probabilistic Inference”. In: *Proceedings of the Twelfth Conference on Uncertainty in Artificial Intelligence*. 1996, pp. 211–219.

[4] Rina Dechter. “Bucket elimination: A unifying framework for probabilistic inference”. In: *Learning in graphical models*. Springer, 1998, pp. 75–104.

[5] Rina Dechter and Irina Rish. “Mini-Buckets: A General Scheme for Generating Approximations in Automated Reasoning”. In: *Proceedings of the Fifteenth International Joint Conference on Artificial Intelligence*. 1997, pp. 1297–1303.

[6] Reinhard Diestel. *Graph Theory*. 5th ed. Springer, 2017.

[7] Eugene F. Dumitrescu, Allison L. Fisher, Timothy D. Goodrich, Travis S. Humble, Blair D. Sullivan, and Andrew L. Wright. "Benchmarking Treewidth as a Practical Component of Tensor Network Simulations". In: *PLOS ONE* 13.12 (2018), e0207827. doi: 10.1371/journal.pone.0207827.

[8] Paul Erdős and Alfréd Rényi. "On Random Graphs I". In: *Publicationes Mathematicae (Debrecen)* 6 (1959), pp. 290–297.

[9] Edgar N. Gilbert. "Random Graphs". In: *The Annals of Mathematical Statistics* 30.4 (1959), pp. 1141–1144. doi: 10.1214/aoms/1177706098.

[10] Johnnie Gray and Garnet Kin-Lic Chan. "Hyperoptimized Approximate Contraction of Tensor Networks with Arbitrary Geometry". In: *Physical Review X* 14.1 (2024), p. 011009. doi: 10.1103/PhysRevX.14.011009.

[11] Johnnie Gray and Stefanos Kourtis. "Hyperoptimized Tensor Network Contraction". In: *Quantum* 5 (2021), p. 410. doi: 10.22331/Q-2021-03-15-410.

[12] Nathan Halko, Per-Gunnar Martinsson, and Joel A. Tropp. "Finding Structure with Randomness: Probabilistic Algorithms for Constructing Approximate Matrix Decompositions". In: *SIAM Review* 53.2 (2011), pp. 217–288. doi: 10.1137/090771806.

[13] Mike Heddes, Igor Nunes, Tony Givargis, and Alex Nicolau. "Approximating Tensor Network Contraction with Sketches". In: *arXiv preprint arXiv:2603.07387* (2026).

[14] Cupjin Huang, Fang Zhang, Michael Newman, Xiaotong Ni, Dawei Ding, Junjie Cai, Xun Gao, Tenghui Wang, Feng Wu, Gengyan Zhang, et al. "Efficient Parallelization of Tensor Network Contraction for Simulating Quantum Computation". In: *Nature Computational Science* 1 (2021), pp. 578–587. doi: 10.1038/s43588-021-00119-7.

[15] Jonathan Jakes-Schauer, David Anekstein, and Pawel Wocjan. "Carving-width and Contraction Trees for Tensor Networks". In: *arXiv preprint arXiv:1908.11034* (2019).

[16] Michael Levin and Cody P. Nave. "Tensor Renormalization Group Approach to Two-Dimensional Classical Lattice Models". In: *Physical Review Letters* 99.12 (2007), p. 120601. doi: 10.1103/PhysRevLett.99.120601.

[17] Linjian Ma, Matthew T. Fishman, E. Miles Stoudenmire, and Edgar Solomonik. "Approximate Contraction of Arbitrary Tensor Networks with a Flexible and Efficient Density Matrix Algorithm". In: *Quantum* 8 (2024), p. 1580. doi: 10.22331/q-2024-12-27-1580.

[18] Igor L. Markov and Yaoyun Shi. "Simulating Quantum Computation by Contracting Tensor Networks". In: *SIAM Journal on Computing* 38.3 (2008), pp. 963–981. doi: 10.1137/050644756.

[19] Román Orús. "A Practical Introduction to Tensor Networks: Matrix Product States and Projected Entangled Pair States". In: *Annals of Physics* 349 (2014), pp. 117–158. doi: 10.1016/j.aop.2014.06.013.

[20] Feng Pan, Pengfei Zhou, Sujie Li, and Pan Zhang. "Contracting Arbitrary Tensor Networks: General Approximate Algorithm and Applications in Graphical Models and Quantum Circuit Simulations". In: *Physical Review Letters* 125.6 (2020), p. 060503. doi: 10.1103/PhysRevLett.125.060503.

[21] Ninh Pham and Rasmus Pagh. "Fast and Scalable Polynomial Kernels via Explicit Feature Maps". In: *Proceedings of the 19th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2013, pp. 239–247. doi: 10.1145/2487575.2487591.

A 附录

A.1 方法细节与机制补充

为了使上述方法具有可复现性，这里进一步说明划分树构造、输出分块、局部块键缓存、根节点读出、精确收缩基线以及随机化压缩的可重复性设置。

划分树构造。 设张量网络的交互图为 $G=(V,E,w)$，其中每个节点对应一个原始张量；若两个张量共享内部标签，则在它们之间连边。当前实现中，边权由共享内部标签的维度贡献累加得到。在任意子图 $G[U]$ 上，我们递归执行一次二分：若子图连通，则使用 Stoer–Wagner min-cut 得到 U_L, U_R；若子图退化或无边，则回退为“单节点 vs 其余节点”的划分。据此自底向上构造一棵划分树。对于任意树节点 v（对应子网络 $\mathcal{N}_v$），其输出标签、边界标签与切割标签分别记为 $\mathcal{O}_v, \mathcal{B}_v, \mathcal{C}_v$。

输出分块。 设全局开放标签顺序为 $\mathcal{O}=(\ell_1,\dots,\ell_m)$。实现中，从开放标签顺序的前部选取若干标签作为分块轴，并将每个被分块标签的索引集合划分为等长的连续片段。一个输出块 Ω_b 即为这些局部片段的笛卡尔积。正文默认设置对应的具体实现是：沿前两个开放输出轴做分块，且每个分块轴上的局部片段长度为 1。

局部块键与块间缓存。 设输出块 Ω_b 在被分块输出标签 ℓ 上对应的局部索引集合记为 $I_{b,\ell}\subseteq[d_\ell]$。在正文默认设置中，由于每个分块轴都按单索引块切分，故 $I_{b,\ell}$ 退化为单元素集合。

对树节点 v 和输出块 Ω_b，我们定义其局部块键

$$\kappa_v(\Omega_b)=\big\{(\ell, I_{b,\ell}) \,:\, \ell\in\mathcal{O}_v,\ \ell \text{ 参与当前输出块的分块}\big\}.$$

也就是说，$\kappa_v(\Omega_b)$ 只保留该子树真正“看得见”的局部切片条件，而忽略与该子树无关的其他块信息。于是，节点状态缓存可写为

$$K(v,\Omega_b)=\big(\text{node_key}(v),\ \kappa_v(\Omega_b),\ \text{sig}(\theta)\big),$$

其中 $\text{sig}(\theta)$ 表示与压缩相关的配置签名（如秩选择策略、容忍度、随机化参数和优化策略等）。只要两个全局输出块在节点 v 上诱导出相同的 $\kappa_v(\Omega_b)$，则该节点状态即可直接复用。

根节点读出。 在根节点处，外部边界已经为空，因此根状态不再对应“输出侧 $\times$ 边界侧”的接口矩阵，而是直接对应当前块的输出。若仍将其写成低秩因子形式

$$M_{\text{root}}\approx A_{\text{root}}B_{\text{root}}^{\top},$$

则当前块输出可通过对中间秩索引求和得到。

精确收缩基线。 本文的精确收缩基线 exact-TNC 与 AS-TNC 共用同一张量网络实例、同一开放标签顺序以及同一组输出块。对每个输出块 Ω_b，exact-TNC 直接对完整网络执行一次精确收缩，并将所得结果写回对应的输出位置。因此，exact-TNC 与 AS-TNC 的差别不在输出接口，而在于内部收缩组织方式：前者对每个输出块直接执行全网络精确 contraction，后者则通过划分树上的分隔状态递归完成近似收缩。

exact-TNC 作为精确收缩基线，其底层通过 `opt_einsum.contract` 实现。`opt_einsum` 是一个标准的 einsum 风格张量收缩库，能够自动选择并执行优化后的 contraction path。除特别说明外，本文在 exact-TNC 中统一采用 `optimal` 路径策略。

A.2 关键实验配置与可复现细节

本小节补充正文未展开但会显著影响结果解释与复现实验的关键设置。

网络构造规则 网络采用 `networkx` 库生成。Tree-8 使用 `random_labeled_tree`；Random-8 使用 `networkx.erdos_renyi_graph` 并重复采样直至连通，边概率 $p=0.35$。两者都由全局随机种子驱动（主实验种子为 $\{0,1,2\}$）。

容忍度与强度预设 实现中对叶子和合并操作使用不同的容忍度 τ_{leaf} 和 τ_{merge}，强度扫描三档分别为

$$\begin{aligned}
&\text{L1} \quad (5.0\times10^{-4},\ 2.0\times10^{-3})\\
&\text{L2} \quad (1.0\times10^{-3},\ 5.0\times10^{-3})\\
&\text{L3} \quad (3.0\times10^{-3},\ 1.5\times10^{-2})
\end{aligned}$$

另外，AS-TNC 采用 `depth_open` 调度：节点局部容忍度按

$$\tau_{\text{local}}=\tau_{\text{base}}\cdot(1.5)^{\text{depth}}/(\max(1,\text{open_count}))^{0.5}$$

自适应调整。

正文默认分块设置的精确定义 正文主实验默认采用如下块级设置：沿前两个开放输出轴逐块生成完整输出，且每个输出块在这两个轴上各只包含一个索引位置。在实现层面，这对应于选取前两个开放标签参与分块，并将每个被分块标签按长度为 1 的局部片段切分。正文不直接使用实现变量名来描述该设置，是为了把默认设定解释为一种块级计算策略，而不是一组代码开关。

计时与汇总口径。 本文采用同任务、同分块、分阶段的统一计时口径。对每个网络实例，先生成同一组输出块，再在该分块上分别运行 exact-TNC 与近似方法；因此，不同方法面对的是相同的输出组织与写回负担。计时使用高精度时钟，并将每个输出块的时间拆分为收缩与写回两段并累计，最终报告

$$T_{\text{total}}=T_{\text{contract}}+T_{\text{emit}}.$$

同时给出 $t_{\text{contract}}/t_{\text{total}}$ 作为阶段占比指标。

主结果统一在随机种子 $\{0,1,2\}$ 上重复运行。除特别说明外，表中报告的相对误差、收缩时间、总时间、阶段占

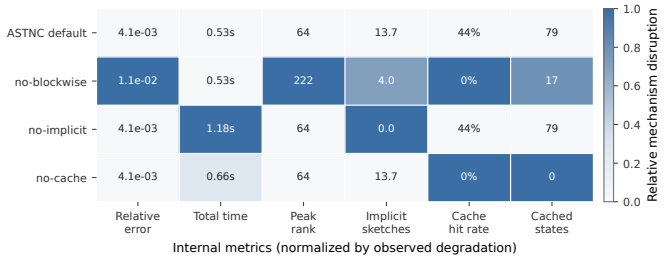

Figure 2: Grid 3×3 上的机制指纹图。按指标归一化后，不同变体的主要退化方向变得更清晰：no-blockwise 主要抬高误差与峰值秩，no-implicit 主要恶化运行时间，no-cache 则主要击穿复用相关统计。

比与缓存命中率均为三个种子结果的算术平均。速度提升统一定义为

$$\text{speedup} = T_{\text{exact-TNC}}/T_{\text{method}},$$

并由平均总时间之比计算。

A.3 补充实验结果与机制证据

本节补充正文未完全展开的三个问题：第一，正文默认 AS-TNC 配置在 Grid 3×3 上到底对应什么；第二，不同机制变体的影响究竟落在哪些内部指标上；第三，输出分块为何更像是在定义一个设计空间，而不只是一个简单开关。

正文默认配置的精确定义。 正文中 Grid 3×3 的默认配置对应中等强度预设 ASTNC-L2，并同时启用输出分块、隐式草图合并和块间缓存复用。这里的输出分块采用前两个开放输出轴上的单元素小块。其对应实现参数分别为 `block_label_count=2` 与 `chunk_size=1`。

该配置在三个随机种子上的平均结果为：相对误差 4.08×10^{-3}，收缩时间 0.5340 秒，总时间 0.5342 秒，相对 exact-TNC 的加速为 88.45×，缓存命中率为 0.440。因此，正文中的主结果表、机制表以及后文的 blockwise / cache 补充证据都以这一默认配置为统一参照。

机制指纹视角。 仅看总时间还不足以区分不同机制到底影响了什么。Figure 2 将 Grid 3×3 上的关键内部指标做了归一化汇总。可以看到，去掉隐式草图合并主要伤害运行时间；去掉缓存主要击穿复用相关统计并带来次级降时损失；而去掉输出分块则主要抬高误差与峰值秩。因此，这几个组件并不是在做同一件事，而是在分别塑造精度、运行时间与中间状态规模。

输出分块作为设计空间。 为了进一步理解默认配置为何选择“沿前两个输出轴、按单索引块逐块生成”的设置，我们在 Grid 3×3 上做了局部 blockwise 扫描。Figure 3 以设计空间的方式展示了这些结果：主图聚焦 practical operating region，而 near-exact 的设置被单独放入 inset，从而避免极小误差点把整张图的误差轴压扁。在这样的视图下，正文默认配置的角色更清楚了：它并不是误差最低、也不是时间最短，而是在当前候选项中提供了更均衡的工作点。因此，默认设置并不是任意选取，而是在误差、时间、峰值秩与复用行为之间做出的平衡。

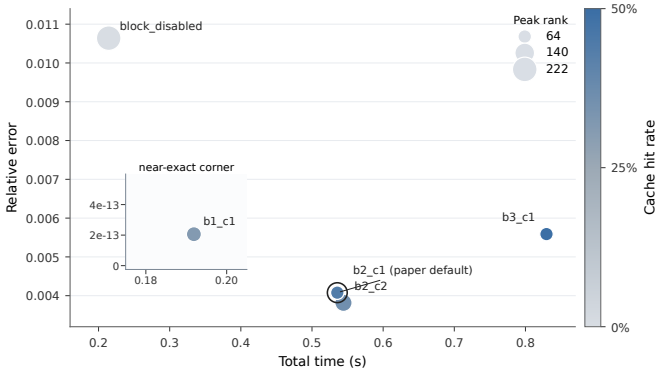

Figure 3: Grid 3×3 上的 blockwise 设计空间。主图聚焦 practical operating region，点面积编码 peak rank、颜色编码 cache hit rate；inset 单独展示 near-exact 设置，从而使正文默认配置能以“平衡点”而非“被压扁的中间点”被读出。